

Problem Chosen

A

2026

**MCM/ICM
Summary Sheet**

Team Control Number

5049

Summary

Keywords:

Contents

1	Introduction	4
1.1	background	4
1.2	Restatement of the Problem	4
1.3	Literature Review	4
1.4	Our Work	5
2	Assumptions and Justification	5
3	Notations	6
4	Establishment of The Continuous-Time Model and Results Analysis	6
4.1	Establishment of The Model	6
4.1.1	模型 I: 电池等效电路模型	6
4.1.2	模型 II: 功率负载模型	7
4.1.3	模型 III: 热力学模型	9
4.1.4	多物理场的参数耦合	10
4.2	模型参数识别	10
4.3	模型验证	11
5	时间预测模型的建立与结果分析	12
5.1	预测模型的建立	12
5.1.1	状态空间模型构建	12
5.1.2	电池寿命模型	14
5.2	结果分析	14
5.2.1	预测结果分析	14
5.2.2	有效性分析	16
5.2.3	不确定性分析	18
6	Sensitivity Analysis	19
6.1	不同环境温度对续航时间的影响	19
6.2	模型系数 β_2 对模型的影响	20
6.3	不同屏幕亮度对模型的影响	20
6.4	屏幕亮度对电池性能的影响分析	20
6.5	网络吞吐量对电池的影响	20
6.6	内阻模型对 SOH 退化预测的影响	21
7	Recommendations	22
7.1	针对用户的使用建议	22
7.2	针对 OS 的建议	22
8	Model Evaluation and Further Discussion	23
8.1	Strengths	23
8.2	Weaknesses	23
9	Conclusion	23


Reference

24


1 Introduction

1.1 background

随着科学技术的发展，手机在我们的生活中发挥着不可或缺的作用。到 2025 年，全球智能手机用户数量已超过 73 亿。



(a) 全球手机用户数量 [12]



(b) 手机电池电量示意图

图 1

其中，手机的续航能力直接影响用户体验，而电池作为手机的核心部件，与屏幕、CPU 工作情况、网络负载、应用程序相互配合，共同作用，决定着手机的续航时间进而影响用户的使用体验。因此，在不同的使用情况，不同的环境条件下，准确估计手机电池的剩余电量与续航时间，对于提升用户体验具有重要意义。

1.2 Restatement of the Problem

基于上述的理解，我们的任务是建立一个常微分方程（ODE）系统，以描述在实际使用场景下随时间变化的充电状态（SOC）的演变情况。具体而言，本研究将尝试完成以下几个任务：

- **任务一：** 建立一个连续时间模型来表示电池的电量状态，并且模型能从电池放电的简单状态拓展到复杂多场景条件。
- **任务二：** 利于上述模型来预测出不同初始充电水平和使用场景下的手机续航时间。将结果进行分析以量化模型的不确定性，并评估该模型的有效性。
- **任务三：** 通过调整假设与模型参数，对上述建立的模型进行灵敏性分析以评估模型稳定性。
- **任务四：** 为终端用户以及操作系统设计者制定相应的建议从而增强电池的续航时间。

1.3 Literature Review

准确的识别电池的 State of Charge (SOC) 是先进的电池管理系统（BMS）的核心任务之一。在电动汽车方面，Hui Pang and Fengqi Zhang 提出了一种基于系统实验数据驱动的参数识别方案以及一种基于自适应扩展卡尔曼滤波（AEKF）的锂离子电池等效电路模型的 SOC 估算算法 [11]; Yixing

Chen , Deqing Huang 等人基于分数阶微积分理论开发了一个改进的二阶 RC 模型来模拟锂离子电池的特性 [6]。结果表明，他们实现了在不同工况下对 SOC 的高精度与高效率估计，验证了该类模型在动态负载条件下的有效性和可行性。

在移动消费类电子设备领域，受限与电池容量，锂电池功率能耗模型与能量管理策略同样受到关注 [1]。已有研究从系统层面对智能手机的主要能耗来源进行了分析，构建了以 CPU、GPU 和显示屏等高能耗组件为核心的功率模型，并基于不同工作负载阶段对设备总体功耗进行预测，从而估算电池消耗量与剩余可用时间 [9]。此外，通过应用动态卸载技术到移动设备能耗模型（包括 CPU、显示单元、无线网络接口和内存）在移动设备上可实现 18% 至 55% 的能效提升，具体提升幅度取决于不同的条件 [2]。这些研究揭示了用户行为与系统负载对电池消耗的显著影响，并为多场景下的模型中各子项的合理取值提供了理论与实验依据。

1.4 Our Work

受到上述研究的启发，本研究将构建基于连续时间的电池电量模型与基于 UKF 的时间预测模型。具体流程如图 2 所示：




图 2: 流程图

2 Assumptions and Justification

Assumption 1: 手机电源管理链路对电池侧呈现近似恒功率取能。

智能手机典型为稳压供电架构，负载功耗更接近功率而非恒流；将复杂电源管理折算为常效率可显著简化耦合并保持物理一致性。

Assumption 2: 开路电压 $E(SOC)$ 仅由 SOC 决定，并可用离线拟合的多项式 $E(z)$ 近似表示；在给定的电池类型与温区内该映射保持稳定。

OCV-SOC 关系是求解电压观测方程的关键，我们采用拟合函数等价于“查表法”，可避免引入

更高维的电化学状态变量，保证 UKF 可实现。

Assumption 3: 总功率 $P(t)$ 可分解为待机、屏幕、CPU、GPS、网络、后台等可加和分量，且每一分量可由可观测/可设定的场景变量（亮度、CPU 利用率、信号强度、数据传输量等）驱动。

题目中明确了电池模型需要从简单放电扩展到多场景。将总功率分解为可观测的场景变量，便于场景拼接与灵敏度分析。

Assumption 4: 电池温度 $T(t)$ 可视为单一集中参数（空间上均匀），与环境的散热满足牛顿冷却定律，并且换热系数 h 与散热面积 A 在短时间内不变。

手机电池体积较小、导热快，用 0D 热模型即可捕捉主要温升趋势；该假设使热-电耦合仍保持低维 ODE，适合仿真与滤波。

3 Notations

表 1: Key notations used in this paper

Symbol	Description	Unit
$SOC(t)$	State of Charge	—
$U(t)$	Battery terminal voltage	V
$U_{meas}(k)$	Measured terminal voltage at step k	V
$E(SOC)$	Open-circuit voltage (OCV)	V
$i(t)$	Battery current	A
Δt	Sampling period / discretization step	s
R_0	Ohmic internal resistance	Ω
R_1, R_2	Polarization resistances in the 2-RC model	Ω
C_1, C_2	Polarization capacitances in the 2-RC model	F
$U_1(t), U_2(t)$	RC polarization voltages	V
Q_n	Rated/available battery capacity	Ah
$P(t)$	Total phone power demand (load power)	W
$T(t)$	Battery/device temperature	$^{\circ}\text{C}$
T_{env}	Ambient temperature	$^{\circ}\text{C}$
$SOH(t)$	State of Health (capacity/health indicator)	—

4 Establishment of The Continuous-Time Model and Results Analysis

4.1 Establishment of The Model

4.1.1 模型 I: 电池等效电路模型

题目明确规定假设手机电池为锂电池，考虑各种锂电池充放电过程中包括欧姆极化，电化学反应，浓差极化，在内的极化反应及模型计算复杂度与真实度，我们选用二阶 RC 等效电路模型模拟锂电池内部结构，近似描述电池内部的动态过程，其等效电路如Figure 3所示。

其中 E 是电池的开路电压，取决于 State of Charge (SOC)，是表示电池荷电状态 (SOC) 的函数， i_t 为电路总电流， U 为电池端输出电压。根据基尔霍夫定律可以此得到电池端输出电压 U 的表




图 3: 二阶 RC 等效电路模型示意图

达式：

$$U = E - U_0 - U_1 - U_2 \quad (1)$$

其中，欧姆内阻上的压降满足欧姆定律 $U_0 = i_t * R_0$ ，由此得：

$$U = E(SOC) - i_t * R_0 - U_1 - U_2 \quad (2)$$

同时，根据基尔霍夫电流定律，第一个并联回路电流关系满足 $i_t = i_{R1} + i_{C1}$ ，从而第一个回路的微分方程可以表示为：

$$\frac{dU_1}{dt} = \frac{i_t}{C_1} - \frac{U_1}{R_1 C_1} \quad (3)$$

对于第二个并联回路，同理可得：

$$\frac{dU_2}{dt} = \frac{i_t}{C_2} - \frac{U_2}{R_2 C_2} \quad (4)$$

为了使得最后模型求解闭环，我们定义 SOC 变化方程：

$$\frac{dSOC}{dt} = -\frac{i_t}{Q_n} \quad (5)$$

其中 Q_n 是电池额定容量，负号表示放电导致 SOC 减小。

综上，可得到电池模型的状态方程：

$$\begin{aligned} \frac{dU_1}{dt} &= \frac{i(t)}{C_1} - \frac{U_1}{R_1 C_1} \\ \frac{dU_2}{dt} &= \frac{i(t)}{C_2} - \frac{U_2}{R_2 C_2} \\ \frac{d(SOC)}{dt} &= -\frac{i(t)}{Q_n} \end{aligned} \quad (6)$$

以及对应的输出方程：

$$U(t) = E(SOC) - i(t) * R_0 - U_1 - U_2 \quad (7)$$

4.1.2 模型 II：功率负载模型

在真实的手机放电过程中，电池放电电流并非恒定的额定值，而是由手机各组件的瞬时功率需求共同决定；同时，功率需求又可以由用户的使用行为进行映射。基于此，我们将电池输出的总功率分解为基础待机功率 P_{base} 、屏幕使用功率 P_{screen} 、CPU 使用功率 P_{CPU} 、GPS 使用功率 P_{GPS} 、网络使用功率 $P_{networking}$ 以及后台功率 $P_{background}$ ，得到总功率表达式：

$$P(t) = P_{base} + P_{screen}(t) + P_{CPU}(t) + P_{GPS}(t) + P_{networking}(t) + P_{background}(t) \quad (8)$$

另一方面，手机内部的电源管理芯片通常以近似恒定功率模式从电池取电。由功率定义 $P = UI$ ，可得电池电流 $i(t)$ 为：

$$i(t) = \frac{P}{U(t) * \eta} \quad (9)$$

其中 η 为 DC-DC 转换器的效率，通常取接近 1 的常值。 $U(t)$ 为电池端输出电压。

为准确刻画手机在不同使用场景下的功率特性，我们针对各个功耗组件建立了基于物理原理和实测数据的数学模型。

基础功耗 基础功耗 P_{base} 代表手机在开机但没有任何用户活动时，维持系统存活的最低功耗，包括操作系统内核、时钟芯片、内存待机必要开销。该项为常数：

$$P_{base} = P_0 \quad (10)$$

其中 P_0 通常在 0.2-0.5 W 之间，取决于具体手机型号。

屏幕功耗模型 由韦伯定律可知，人眼对光强的感知呈对数关系，因此为了让用户感觉亮度线性变化，屏幕的实际输出功率必须呈现指数或幂函数增长。我们定义屏幕功耗模型为：

$$P_{screen}(t) = \delta_{on}(t) * P_{drive} + \alpha_s * (B(t)^\gamma) \quad (11)$$

其中： $\delta_{on}(t) \in \{0, 1\}$ 表示屏幕开关状态， P_{drive} 为屏幕驱动的基础功耗， $B(t) \in (0, 1)$ 为屏幕亮度百分比， γ 为伽马校正系数，通常在 1.5 到 2.2 之间。根据文献 [4] 的实测数据，实际应用中取：

$$P_{screen}(t) = 1.08 + 0.72 * B(t)^{2.0} \quad (12)$$

处理器功耗模型 在物理上，集成电路的动态功耗满足 $P = C * V^2 * f$ ，对于现代 CPU，当负载 u 增加时，不仅提高频率 f ，还会提高电压 V 。由于电压 V 通常与频率 f 成正比，故功耗正比于频率的三次方。又因为 CPU 利用率 u 与频率 f 成正相关，所以功耗与利用率的关系为非线性。我们采用二次多项式模拟此现象：

$$P_{CPU}(t) = P_{idle} + \beta_1 * u(t) + \beta_2 * u(t)^2 \quad (13)$$

其中： P_{idle} 为 CPU 空闲状态功耗， $u(t) \in [0, 1]$ 为 CPU 利用率， β_1, β_2 为模型系数。（可利用边界条件法确认，通过最大功耗和最小功耗，通过物理直觉确定两者比例，然后后续进行灵敏度分析）通过边界条件确定参数：CPU 最低工作功率为 0.36 W ($u = 0.1$ 时)，最高工作功率为 2.88 W ($u = 1$ 时)。考虑到手机大部分时间处于低负载状态，线性功耗占主要比重，取：

$$P_{CPU}(t) = 0.1 + 2.58 * u(t) + 0.2 * u(t)^2 \quad (14)$$

GPS 功耗模型 GPS 通常在启动阶段（活跃阶段）消耗最高功耗，成功定位后功耗显著降低。定义 GPS 功耗模型为：

$$P_{GPSt} = \delta_{gps}(t) * P_{GPS-active} \quad (15)$$

其中， $\delta_{gps}(t) \in \{0, 1\}$ 为 GPS 的开关状态， $P_{GPS-active}$ 为 GPS 活跃时的功耗。

网络连接功耗模型 根据通信原理，为了维持恒定的信噪比以保持连接，当距离变远或障碍物增加时（信号强度 S 变小），手机必须提高发射功率。模型定义为：

$$P_{networking}(t) = \delta_{network}(t) \cdot (P_{base_{net}} + \frac{P_{ref}}{S_{sianal}(t)} * D_{throughput}(t)) \quad (16)$$

其中， $\delta_{network}(t) \in \{0, 1\}$ 表示网络模块开关状态， $S_{sianal}(t) \in (0, 1]$ 为信号强度因子，1 表示信号最好， $D_{throughput}(t)$ 为数据传输速率（Mbps）， P_{ref} 为参考发射功率，一般取 0.3-0.4 W。

后台任务功耗模型 后台任务的最大特点是间歇性，不是持续运行，而是周期性唤醒。引入脉冲序列模型：

$$P_{background}(t) = \sum_k P_{task} \cdot \prod(\frac{t - t_k}{\tau}) \quad (17)$$

其中， $\prod$ 为矩形窗函数，表示任务持续一小段时间， t_k 表示第 k 次唤醒的时间点， P_{task} 为唤醒时的功率，由手机工作状态决定。矩形窗函数定义为：

$$\prod(\frac{t - t_k}{\tau}) = \begin{cases} 1 & t_k \leq t < t_k + \tau \\ 0 & \text{其他} \end{cases} \quad (18)$$

其中 τ 为单次后台任务的持续时间。

4.1.3 模型 III：热力学模型

温度是影响电池性能的重要因素之一。电池温度不仅会改变电池内部电化学反应速率，还会进一步影响电池内阻、可用容量以及放电效率。因此，为了提高电池状态预测模型的准确性，有必要建立电池热动力学模型来描述电池温度的动态变化过程。在实际工作中，手机系统的热量来源主要包括两个部分：一是电池内部由于电流通过内阻产生的焦耳热；二是由系统级负载产生的附加热量，例如处理器、射频模块功率损耗以及显示器损耗等。因此，为了同时描述电池内部物理发热以及系统级功耗引起的产热效应，我们将整个手机产生的总热量表示为两部分之和，即

$$Q_{gen}(t) = i^2(t) * R_0 + \alpha * P(t) * T \quad (19)$$

其中，第一项表示电池内部欧姆内阻引起的焦耳热；第二项表示由电池输出的总能量转化为热量的附加热能。参数 α 表示总能量向热能转化的比例系数。考虑到实际电子设备中并非全部电能都会转化为热能，本文参考消费电子设备的典型热效率范围，在后续仿真中取 $\alpha = 0.1$ ， T 代表场景运行总时长。

与此同时，电池在工作过程中还会向环境不断地散热。根据牛顿冷却定律，散失的热量与电池和环境温差成正比：

$$Q_{diss}(t) = h * A * (T(t) - T_{env}) \quad (20)$$

其中 h 为对流换热系数， A 为有效散热面积， T_{env} 为环境温度。

根据能量守恒定律，电池温度 $T(t)$ 的动态方程可以表示为：

$$mC_p \frac{dT(t)}{dt} = Q_{gen}(t) + Q_{diss}(t) \quad (21)$$

其中， m 为电池质量， C_p 为电池比热容。

4.1.4 多物理场的参数耦合

温度会进一步改变等效电路模型的参数，从而形成多物理场耦合。电池内阻随温度变化遵循阿伦尼乌斯方程，温度越低离子活性越差，内阻越大

$$R(T) = R_{ref} * \exp\left(\frac{E_a}{k}\left(\frac{1}{T(t)} - \frac{1}{T_{ref}}\right)\right) \quad (22)$$

此外，电池的总容量 Q_n 也并非恒定不变，在低温场景下，其可用化学容量会产生衰减，可以表示为：

$$Q_n(T) = Q_{max} \cdot \eta_T(T) \quad (23)$$

其中， $\eta_T(T)$ 为温度对可用化学容量的衰减因子，是温度的函数。

4.2 模型参数识别

在锂电池实际工作中， E 和 SOC 是存在函数关系。因此，首先，我们通过真实数据采用 5 阶拟合的方式，定义归一化荷电状态 $z = SOC(t) \in [0, 1]$ ，得到其近似函数表达式：

$$E(z) = 4.5784 * z^5 + -13.0395 * z^4 + 13.4836 * z^3 + -5.5077 * z^2 + 1.1662 * z + 3.4835 \quad (24)$$

此多项式将作为后续时域仿真的静态查表函数，用于根据实时 SOC 估算开路电压 E 。




图 4: E-SOC 曲线

然后，由于实际系统控制与参数辨识均在离散时间域进行，需将连续时间的状态方程转换为离散形式。设采样周期为 Δt ，基于前向欧拉和指数离散化方法，得到二阶 RC 模型的离散状态递推方程：

$$\begin{aligned} U_1(k+1) &= \exp\left(-\frac{\Delta t}{R_1 C_1}\right) U_1(k) + R_1 \left[1 - \exp\left(-\frac{\Delta t}{R_1 C_1}\right)\right] i(k) \\ U_2(k+1) &= \exp\left(-\frac{\Delta t}{R_2 C_2}\right) U_2(k) + R_2 \left[1 - \exp\left(-\frac{\Delta t}{R_2 C_2}\right)\right] i(k) \\ SOC(k+1) &= SOC(k) - \frac{\eta \cdot i(k) \cdot \Delta t}{Q_n} \end{aligned} \quad (25)$$

最后，为避免传统实验法对精密设备和大量先验数据的依赖，本研究采用遗传算法 (Genetic Algorithm, GA) 对二阶 RC 等效电路模型进行全局参数辨识。定义参数向量 $\theta = [R_0, R_1, R_2, C_1, C_2, SOC_0]^T$ 其中 SOC_0 为初始荷电状态。基于最小二乘原理，构建以端电压误差最小化为目标的损失函数：

$$J(\theta) = \sqrt{\frac{1}{N} \sum_{k=1}^N [U_{meas}(k) - U(k)]^2} \quad (26)$$

其中, $U_{meas}(k)$ 为 k 时刻的实测电压数据。 $U(k)$ 为模型在当前参数下的仿真电压, N 为数据序列长度。

基于 GA 的迭代优化流程如 Algorithm1所示:

Algorithm 1 GA-based Parameter Identification

Require: Current profile $I(t)$, measured voltage U_{meas} , OCV polynomial $E(z)$, capacity Q_n

Ensure: Optimal parameter vector $\theta^* = [R_0, R_1, C_1, R_2, C_2, SOC_0]^T$

```

1: Initialize population with bounds constraints
2: for  $gen = 1$  to  $G_{max} = 200$  do
3:   for each individual  $\theta_i$  in population do
4:      $U \leftarrow \text{run\_model}(\theta_i, I, t, E(z), Q_n)$ 
5:      $J_i \leftarrow \sqrt{\text{mean}((U_{meas} - U)^2)}$ 
6:   end for
7:   if  $\min(J) < 10^{-4}$  or stall count  $> 20$  then
8:     break
9:   end if
10:  Selection, Crossover ( $P_c = 0.8$ ), Mutation ( $P_m = 0.1$ )
11: end for
12: return  $\theta^* = \arg \min J(\theta)$ 


```

- Step 1: 状态初始化, 设定初始条件: $U_1(0) = 0, U_2(0) = 0$, 初始荷电状态 $SOC(0) = SOC_0$ 。根据编码方案生成初始种群, 每个个体代表一组候选参数 θ 。
- Step2: 时域仿真迭代。根据当前 $SOC(k)$, 代入拟合得到的多项式函数计算电池开路电压 $E(SOC(k))$ 。根据当前 $E(SOC(k))$, 代入模型得到电池的仿真电压 $U(k)$ 。然后, 状态递推, 利用离散状态迭代方程Equation 25, 根据当前电流和状态量, 计算下一时刻 $SOC(k+1)$, $U_1(k+1)$, $U_2(k+1)$ 。
- Step3: 遗传算法寻优, 利用遗传算法对参数向量进行迭代更新。首先根据适应度函数, 选择优秀个体并进行交叉变异。然后重复之前步骤, 直到误差小于阈值或达到最大迭代次数。


4.3 模型验证

为验证所建立的二阶 RC 模型的准确性, 首先我们采用动态应力测试 (DST) 工况对模型进行验证, 测试时长约 2.8×10^4 秒, 约 7.78h。覆盖电池从满充状态 (4.2 V) 到接近放空 (3.4 V) 的完整工作区间。然后, 我们用了 一个 100mA 恒流持续放电的数据集进行验证, 结果如Figure 5所示。

Figure 5a上方模型预测的端电压 (红色虚线) 与实测电压 (蓝色实线) 在整个放电过程中表现出高度一致性。在初始准静态阶段 ($0 - 0.9 \times 10^4$ 秒), 模型准确捕捉了电池在 4.2V 附近的平台期特征, 精确反映了初期极化电压的缓慢衰减; 而在 $1.8 \times 10^4 - 2.8 \times 10^4$ 秒之后的动态高负载阶段, 面对模拟真实智能手机使用的脉冲电流波动, 模型展现出优异的瞬态跟踪能力, 能够精确复现电压尖峰及其恢复动态。



(a) DST 动态应力测试验证



(b) 100mA 恒流放电测试验证

图 5: 二阶 RC 模型在动态工况与标准恒流工况下的验证结果对比

Figure 5a 下方的误差分析进一步量化了模型的预测精度。在平缓放电区间，预测误差基本维持在 $25mV$ 左右，在剧烈脉冲循环阶段，误差与电流纹波同步振荡，大部分误差控制在 $\pm 20mV$ 范围内，统计结果表明，模型的误差的方均根约为 $13.46mV$ ，平均绝对误差约为 $9.99mV$ 。相对于 $3.7V$ 的额定电压，误差率仅 0.3% 。

Figure 5b(a) 展示了测量电压与模型估计电压的对比，Figure 5b(b) 给出了整个放电过程中的电压估计误差。从结果可以看出，模型估计值与实测值在整个放电过程中高度一致，两条曲线几乎完全重合。从误差的统计特性来看，除了放电末端的异常波动外，大部分时间内误差保持在 $\pm 15mV$ 以内，均方根误差（RMSE）估计约为 $10 - 12mV$ 。

上述验证结果表明，我们所提出的等效电路模型结合遗传算法参数辨识，在真实工况下具备足够的精度用于剩余使用时间（Time-to-Empty）预测，同时确保了其在多样化使用场景下的 SOC 估计可靠性。

5 时间预测模型的建立与结果分析

5.1 预测模型的建立

在第一问建立的多场景的应用功率及温度影响耦合的综合模型的基础上，为了实现对电量的预测，我们采用无迹卡尔曼滤波算法（Unscented Kalman Filter, UKF）对电池 SOC 进行在线估计与预测。

5.1.1 状态空间模型构建

为了描述电池的动态特征，我们定义状态空间模型，将其状态向量 x_k 用 $[U1, k, U2, k, SOC_k]^T$ 来表示。电池的端电压 U 为观测变量 y_k 。

UKF 预测算法设计

UKF 算法主要包括 Sigma 点生成、状态预测以及量测更新三个步骤。

- Step1: 利用当前估计值 $\hat{x}_{k-1}$ 和协方差矩阵 P_{k-1} 构造一组采样点:

$$\begin{cases} X_{0,k-1} = \hat{x}_{k-1}, \\ X_{i,k-1} = \hat{x}_{k-1} + \left(\sqrt{(L+\lambda)\mathbf{P}_{k-1}} \right)_i, & i = 1, \dots, L, \\ X_{i,k-1} = \hat{x}_{k-1} - \left(\sqrt{(L+\lambda)\mathbf{P}_{k-1}} \right)_{i-L}, & i = L+1, \dots, 2L. \end{cases} \quad (27)$$

其中, $L = 3$ 表示状态维度, λ 为缩放比例参数, 用于控制采样点分布范围, X 为 sigma 点集矩阵。

- Step2: 将生成的 sigma 点代入状态方程, 预测下一时刻的状态:

$$\begin{aligned} U_{1,k}^- &= \exp\left(-\frac{\Delta t}{R_1 C_1}\right) U_{1,k-1} + R_1 \left[1 - \exp\left(-\frac{\Delta t}{R_1 C_1}\right)\right] i_{k-1} \\ U_{2,k}^- &= \exp\left(-\frac{\Delta t}{R_2 C_2}\right) U_{2,k-1} + R_2 \left[1 - \exp\left(-\frac{\Delta t}{R_2 C_2}\right)\right] i_{k-1} \\ SOC_k^- &= SOC_{k-1} - \frac{\eta \cdot i_{k-1} \cdot \Delta t}{Q_n} \end{aligned} \quad (28)$$

加权求和得到先验估计:

$$\bar{x}_k = \sum_{i=0}^{2L} W_m^{(i)} X_{i,k|k-1} \quad (29)$$

对应的协方差矩阵为:

$$P_k^- = \sum_{i=0}^{2L} W_c^{(i)} [X_{i,k|k-1} - \hat{x}_{k-1}] [X_{i,k|k-1} - \hat{x}_{k-1}]^T + Q_k \quad (30)$$

其中, W_m , W_c 为权重系数, Q_k 为过程噪声协方差, 代表模型的不确定性。

- Step3: 量测更新。利用预测的 sigma 点通过观测方程, 预测端电压, 并与实际测量的电压 U_{meas} 进行比较来修正。

$$h_{i,k} = E(X_{SOC}) - I_k R_0 - X_{U1} - X_{U2} \quad (31)$$

其中 $E(SOC)$ 为 SOC 与开路电压的非线性映射函数, 前文已经拟合过函数表达式。预测观测值为:

$$\hat{y}_k = \sum_{i=0}^{2L} W_m^{(i)} h_{i,k} \quad (32)$$

- Step4: 卡尔曼增益计算。计算观测自协方差矩阵 S_k 与互协方差 $P_{xy,k}$ 的值

$$\begin{aligned} S_k &= \sum_{i=0}^{2L} W_c^{(i)} [h_{i,k} - \hat{y}_k] [h_{i,k} - \hat{y}_k]^T + R_k \\ P_{xy,k} &= \sum_{i=0}^{2L} W_c^{(i)} [X_{i,k|k-1} - \hat{x}_k^-] [h_{i,k} - \hat{y}_k]^T \end{aligned} \quad (33)$$

所以卡尔曼增益为

$$K_k = P_{xy,k} S_k^{-1} \quad (34)$$

其中 R_k 为测量噪声协方差, 代表电压传感器的误差。

- Step5: 更新预测状态。

$$\begin{aligned} \hat{x}_k &= \hat{x}_k^- + K_k (U_{meas,k} - \hat{y}_k) \\ P_k &= P_k^- - K_k S_k K_k^T \end{aligned} \quad (35)$$

5.1.2 电池寿命模型

与内阻的短期变化不同，电池的寿命衰减是不可逆的累积过程。根据电化学动力学原理，电池内部的副反应速率同样遵循阿伦尼乌斯方程。温度越高，反应速率常数越大，导致（电池健康状态）SOH 下降越快。我们建立基于阿伦尼乌斯的寿命微分模型。

首先，电池的老化速率随温度的变化关系为：

$$k_{\text{aging}}(T) = k_{\text{ref,aging}} \cdot \exp \left[\frac{E_{a,\text{aging}}}{k} \left(\frac{1}{T_{\text{ref}}} - \frac{1}{T(t)} \right) \right] \quad (36)$$

其中 $E_{a,\text{aging}} = 52 \text{ J/mol}$ [7]，表示老化活化能。

接着，考虑到电流对副反应的加速作用，SOH 的微分方程为：

$$\frac{d\text{SOH}}{dt} = -k_{\text{aging}}(T) * |i(t)| \quad (37)$$

最后，电池老化，其寿命衰减又会反过来影响电池的基准内阻，因此考虑老化后的内阻修正模型为：

$$R_{\text{total}}(t) = R(T) * (1 + \alpha(1 - \text{SOH}(t))) \quad (38)$$

其中 α 为内阻增长系数，本题取 1.5。电池老化主要表现为活性锂离子的丧失和活性材料的损失，根据 SOH 的定义，老化后的最大可用化学容量与 SOH 同样呈线性关系，任意时刻 t 和温度 T 下的电池实际有效容量为：

$$Q_n(t, T) = Q_{\text{max}} \cdot \text{SOH}(t) \cdot \eta_T(T) \quad (39)$$

因此，其最终电池荷电状态在电池寿命的影响下，其微分方程也需引入 SOH 的修正。随着 SOH 下降，分母变小，相同的放电电流会导致 SOC 下降得更快了。

$$\frac{d(\text{SOC})}{dt} = -\frac{i(t)}{Q_{\text{max}} \cdot \text{SOH}(t) \cdot \eta} \quad (40)$$

5.2 结果分析

5.2.1 预测结果分析

首先，我们选取了四种典型的用户使用场景（待机 Standby、视频播放 Video、导航 Navigation、游戏 Gaming）覆盖了从低功耗到高功耗的完整使用情况，评估手机电池在初始荷电状态为 1 时的包括电压降特性、温度变化和荷电状态衰减在内的综合表现。结果如 Figure 6 所示，并绘制各场景下电量消耗对比曲线图，如 Figure 7 所示。从电压降曲线以及荷电状态衰减曲线可以清晰地观察到不同




图 6: 电池性能评估结果




图 7: 不同使用场景下的 SOC 衰减率对比

场景下的放电特性差异。高功耗场景（Game、Navi 和 Video）表现出急剧的电压下降，从满电状态到电量耗尽仅持续了约 50 分钟到 150 分钟不等，其中，Game 和 Navi 的曲线更为陡峭，表明这两种场景对电池的负载更大，放电速度更快。相比之下，Standby 待机场景呈现出近似线性的缓慢下降，从 4.15V 满电状态降至 3.45V 的电量耗尽状态，过程持续了约 700 分钟，表明待机状态下电池负载稳定且较轻。

温度变化曲线进一步揭示了各场景的产热特性及其物理机制。Game 场景需要 CPU 和 GPU 高负载运行，导致的产生大量的热量，显示出最显著的温升效应，温度从初始的 25°C 快速上升至约 41.5°C，峰值温度最高且上升速率最快（前 10 分钟内上升约 15°C）。Navi 场景的温度上升至约 38.5°C，温升幅度约 13.5°C，反映了 GPS 模块持续工作、屏幕常亮以及 CPU 地图渲染的综合产热效应。Video 场景的温升相对温和，温度上升至约 34°C，温升幅度约 8.5°C，主要热源来自屏幕显示和视频解码器。Standby 场景的温度基本保持在环境温度 26.5°C 左右，几乎无温升，完全符合低功耗待机的理论预期。

观察 SOC 下降率曲线，四种典型场景的 SOC 耗减速呈现显著分层与时变特征。（Standby）模式下，耗散速率维持在约 8%/小时的恒定水平，全程几乎不受时间影响。视频（Video）、导航（Navigation）与游戏（Gaming）三种中高负载场景均表现出随时间递增的耗散速率。视频播放起始速率约 40%/小时，100 分钟后缓慢攀升至 46%/小时，增幅约 15%。导航与游戏场景所需负载更大，随着使用时长增加，热累积效应显著，整个手机系统产生的热量，对电池温度产生累积性的影响，使得放电速率加快，呈现更为激进的加速耗尽趋势。导航从 57%/小时增至 67%/小时，游戏从 68%/小时激增至近 78%/小时，斜率显著大于视频场景。

接着，我们将电池健康状态（SOH）的长期衰减轨迹与使用场景强度的定量关联，得到了如Figure 8所示的结果。




图 8: 不同使用场景下的 SOH 衰减对比

四种场景的 SOH 衰减呈现显著分层的线性下降趋势,但是斜率差别较大。游戏场景衰减最为激进,仅约 1100 次循环即达寿命终点 (SOH≈0%)。这是因为游戏场景下, CPU 高负载运行导致持续大电流放电,同时产生的热量使电池温度维持高位,根据Equation 36,高温显著加速了副反应速率,导致电池老化加剧。GPS 射频模块的高功耗与屏幕常亮产生的热累积虽略低于游戏,但仍远高于轻度使用,这导致在 Navi 场景下,电池约经历 1250 次循环就会耗尽容量。在 Video 场景下,电流幅值与温度均低于游戏/导航场景,最终经历约 1750 次循环降至失效阈值,老化曲线的斜率相对平缓,但仍比待机快约 2.15 倍。Standby 场景下,低电流与室温工作条件使老化速率常数极小,副反应几乎可忽略,衰减最为缓慢,在经历 2000 次循环后仍保持约 47% 的 SOH,展示了理想保管状态下的电池寿命极限。

5.2.2 有效性分析

接着我们采用 110 分钟的混合使用场景,评估基于无迹卡尔曼滤波 (UKF) 算法的时间预测模型的有效性,结果如Figure 9所示:




图 9: 时间预测模型评估结果

从 SOC 估计结果来看, UKF 算法表现出了优异的跟踪性能。在整个放电过程中 (从 100% 到约 20%), UKF 估计值与真实 SOC 曲线几乎完全重合,两者之间的偏差在视觉上难以分辨。模型性能指标显示,平均 3σ 不确定度仅为 2.36%,这表明算法不仅具有高精度,而且具有良好的可靠性和确定性。特别值得注意的是,在功率负载发生频繁突变的时刻, UKF 算法依然能够准确跟踪 SOC 的动态变化,没有出现明显的滞后或振荡现象。这得益于 UKF 的非线性滤波特性和自适应卡尔曼增益机制,能够根据系统状态和测量噪声实时调整估计策略,有效抑制了累积误差的发散。

功率消耗分解图进一步验证了 UKF 算法在复杂负载条件下的鲁棒性。测试过程涵盖了多种典型使用场景。高负载阶段（总功率约 4.5-5.5W）模拟了游戏场景，此时 CPU 和屏幕分别贡献约 2.5W 和 1.5-2W 的功耗；中等负载阶段（总功率约 3W）模拟了视频场景；低负载阶段（功率低于 0.5W），模拟了待机阶段，仅包含后台任务的周期性脉冲与待机功率。在这些负载变化的不同工况下，UKF 算法始终保持了稳定的估计性能，证明了对不同功率模式的良好适应能力。

总的来说，Figure 9全面展示了本文提出的功率负载模型、二阶 RC 等效电路模型和 UKF 估计算法在实际复杂场景下的优异性能。能够在全 SOC 范围内、多种负载工况下实现高精度的 SOC 估计。

然后，我们进行动态场景下从不同初始 SOC 开始的放电至空预测（Time-to-Empty Prediction），得到了电池剩余使用时间预测模型以及 UKF 算法的误差收敛特性的评估结果，如Figure 10所示。左




图 10: 动态场景下 Time-to-Empty Prediction 评估结果

图为动态场景下从不同初始 SOC 开始的放电至空预测（Time-to-Empty Prediction），右图为 UKF 算法在初始估计值固定为 50% 时的误差收敛过程。这两个子图从不同角度验证了模型的预测能力和算法的自适应性能。

左图展示了考虑动态发热和网络连接影响下的剩余使用时间预测结果，清晰地揭示了电池在混合使用场景下的非线性放电特性。图中绘制了七条 SOC 衰减曲线，分别对应从 100%、80%、60%、50%、40%、30% 和 20% 七个不同初始电量开始放电的情况, 预测的具体结果如Table 2所示。

表 2: 不同 SOC 下的 Time-to-Empty 预测结果

Initial SOC (%)	Time-to-Empty (min)	Avg. Discharge Rate [†] (%/min)
100	133	0.75
80	111	0.72
60	69	0.87
50	54	0.93
40	39	1.03
30	27	1.11
20	19	1.05

结果表明，平均放电速率随着初始 SOC 的降低而加快。这意味着电池的”最后 20%”电量实际上比”电池的平均 20%”消耗得更快。这一现象的物理根源在于多重因素的叠加：（1）电池内阻随

SOC 降低而增大，导致更多能量以热量形式损耗；（2）低 SOC 时电池端电压降低，为维持恒功率输出，电流必须增大，进一步加剧内阻损耗；（3）前期累积的温升效应通过 $\alpha(T)$ 修正因子持续影响放电效率。

右图展示了 UKF 算法在初始估计值存在较大偏差时的误差收敛特性，这是评估状态估计算法鲁棒性的关键指标。实验设计中，所有测试均将初始 SOC 估计值固定为 50%，而真实 SOC 从 100% 到 20% 的七个不同水平，因此初始误差范围从 +50%（真实 100% 时）到 -30%（真实 20% 时）。图中展示了各条件下估计误差随时间的演化过程。

从误差曲线的整体形态来看，UKF 算法展现出卓越的收敛性能。所有初始误差在极短的时间内（约 5-10 分钟）快速收敛至 $\pm 2\%$ 的范围内，随后继续缓慢收敛至 $\pm 1\%$ 以内，并在整个测试期间保持稳定。同时，不同真实 SOC 条件下的稳态误差基本一致，表明算法在全电量范围内具有均匀的估计精度，不存在某些 SOC 区间估计性能明显劣化的问题。对比七条误差曲线可以发现，中等初始误差（如真实 SOC 为 50%，误差为 0%）的情况下，曲线几乎始终保持在 0% 附近，验证了初始值准确时算法的优异性能。而极端初始误差（真实 SOC 为 100% 或 20%）的情况下，虽然初始偏差巨大，但算法依然能在短时间内完成修正，这充分体现了 UKF 算法的鲁棒性。

5.2.3 不确定性分析

此外，我们对建立的基于 UKF 算法预测模型在不同使用场景和初始 SOC 条件下的不确定性量化分析，以评估该模型的可靠性。




图 11: 预测模型在动态场景下的不确定性评估结果

Figure 11 展示了四种典型场景（Standby 待机、Video 视频、Navi 导航、Game 游戏）下从不同初始 SOC 开始的预测轨迹及其不确定性区间；Figure 12 则以三维柱状图的形式综合展示了 16 种场景-初始 SOC 组合（4 场景 $\times$ 4 初始 SOC）的平均 3σ 不确定性水平，提供了定量的、易于比较的不确定性度量，弥补了第一张图定性观察的不足。




图 12: 不同场景和初始 SOC 组合下的平均 3σ 不确定性水平

结果表明，观测信息量与不确定性负相关，且占据主导影响。从 Standby 到 Video、Navi 再到 Game，不确定性呈递减趋势，这与传统的“功耗越高越复杂”的直觉相悖。这是因为观测信息量的主导作用。游戏场景虽然功率波动大（过程噪声大），但电压变化显著（观测信息量大），UKF 能够通过频繁的有效测量更新持续校正估计；相反，待机场景虽然功率稳定（过程噪声小），但电压变化缓慢（观测信息量小），测量更新几乎无法修正模型漂移，导致不确定性累积。同时，SOC 的起始状态会显著的影响该模型的不确定性。所有场景下，20% 起始 SOC 的不确定性均高于 100% 起始的 SOC，且起始 SOC 的差异明显高于场景变化所带来的影响。具体而言，Standby 场景的不确定性从 2% 以下增至 8% 以上，增幅超过 3 倍，而 Game 场景的不确定性则从 2% 以下增至 7% 左右。

6 Sensitivity Analysis

6.1 不同环境温度对续航时间的影响

为了评估环境温度对电池性能的影响，我们选择了 0°C、20°C 和 35°C 三个典型环境温度条件，在四种使用场景下进行 SOC 衰减测试。结果如图 13 所示。




图 13: 不同温度下的 SOC 衰减曲线

结果表明，在任何场景下，温度越低，放电速度更快。例如，在低负载的待机（Standby）场景中，5°C 放电最为快，续航时间最短，约 650 分钟，而在 20, 35°C 下放电较慢，续航时间约 700 分

钟)，变化幅度为 7%。然而，这种温度敏感性随着负载增加而急剧衰减。在视频（Video）、导航（Navi）与游戏（Game）等高负载场景中，代表三种温度的曲线几乎完全重合。其物理根源在于焦耳热主导效应。大电流放电产生的内部产热使电池温度迅速攀升至远高于环境水平的稳定工作温区。此时，无论初始环境温度是 5°C 还是 35°C，电池在实际工作过程中的内部温度轨迹趋于一致，导致温度依赖的内阻与有效容量差异被迅速抹平。因此，用户行为的差异对续航的决定性作用远超环境温度波动影响。

6.2 模型系数 β_2 对模型的影响

定量评估了 CPU 功耗模型中非线性系数 β_2 的敏感性，我们选取了两种参数设置 $\beta_2 = 0.2$ 和 $\beta_2 = 0.5$ ，并比较了两个模型在动态负载下的表现差异，如 Figure 14 所示。




图 14: 不同 β_2 下的 SOC 衰减曲线与功率变化图

左图展现了在完整的 SOC 放电周期（约 120 分钟）内，两条 SOC 衰减曲线轨迹几乎完全重合，右图展现了在完整的 SOC 放电周期（约 120 分钟）内，功率变化曲线，其轨迹也高度一致。这表明两个模型在动态负载下的表现差异不大即 β_2 的取值对总电量消耗影响微弱。

6.3 不同屏幕亮度对模型的影响


6.4 屏幕亮度对电池性能的影响分析

为了评估屏幕亮度对电池性能的影响，本文分别在游戏模式和待机模式下进行了对比实验，设置了 50%、75% 和 100% 三种亮度等级。图 15 展示了两场景下的实验结果。


在游戏场景下，由于 CPU 负载占据主导地位，屏幕亮度对续航时间的影响相对有限，呈现边际效益递减的特征。如图 15a 所示，当屏幕亮度从 100% 降至 50% 时，游戏续航时间仅增加约 10 分钟，这是因为游戏场景的高计算强度使得 CPU 功耗在总功耗中占比更大，屏幕功耗的降低对整体续航的改善效果被部分抵消。相比之下，待机模式下屏幕亮度对电池长期健康状态的影响更为显著。如图 15b 所示，100% 亮度下电池老化最为激进，而 50% 亮度下老化最为缓慢，2000 次循环后 SOH 仍维持在 20% 以上。在待机模式下，屏幕成为主导负载，由于亮度与电流成平方关系，高亮度设置直接加速了基于阿伦尼乌斯方程的副反应进程，导致每轮循环的不可逆损伤累积加剧，从而对电池寿命产生深远影响。

6.5 网络吞吐量对电池的影响

为了评估网络数据传输强度对电池性能的影响，本文分别在游戏模式和待机模式下进行了敏感性分析。Figure 16a 展示了游戏运行时不同网络吞吐量对 SOC 衰减的短期影响，Figure 16b 分析了待




(a) 不同亮度下的 SOC 衰减曲线（游戏场景）




(b) 不同亮度下的 SOH 衰减曲线（待机场景）

图 15: 屏幕亮度对电池性能的影响对比分析

机模式下网络吞吐量对电池寿命的长期影响。两种场景下均设置了三个网络数据传输等级：低数据量 ($D=0.1$)、中等数据量 ($D=0.5$) 和高数据量 ($D=1.0$)。放电初期 (0-20 分钟) 三条曲线几乎完全



(a) 游戏模式下网络吞吐量对 SOC 的影响



(b) 待机模式下网络吞吐量对 SOH 的影响

图 16: 网络吞吐量对电池性能的影响对比分析

重合，而运行到放电后期，网络数据量对 SOC 的影响累积显现，高数据量传输 ($D=1.0$) 导致 SOC 下降最快，而低数据量传输 ($D=0.1$) 则表现出最慢的 SOC 衰减。这种差异源于网络传输功耗在整体功耗中的占比不大，随时间的累积效应逐渐显现。相比之下，待机模式下网络吞吐量对电池寿命的长期影响更为持久，到 2000 个循环时分别降至 39%、44% 和 46%，电池寿命差异约 6-7%。结果表明，在高负载场景中，应优先优化 CPU 和屏幕功耗，而日常待机场景中应重点控制网络活动和后台任务。

6.6 内阻模型对 SOH 退化预测的影响

为了评估内阻模型的准确性对电池健康状态 (SOH) 预测的影响，本文对比了考虑老化效应的混合模型和仅考虑温度影响而忽略老化的简化模型这两种不同的内阻建模方法，结果如Figure 17所

示。




图 17: 不同内阻模型下的 SOH 衰减曲线

从整体趋势来看，混合模型预测的 SOH 衰减速度明显快于简化模型。这种差异源于混合模型中内阻会随循环次数增加而增大，导致更高的欧姆损耗和热量产生，进而加速电池容量衰减。相比之下，简化模型假设内阻保持恒定，无法捕捉老化过程中内阻增加对 SOH 的累积影响，因此倾向于高估电池的实际寿命。

不同使用模式对 SOH 衰减的影响存在显著差异。待机模式因为待机时功率负载极低，电池内部发热和化学反应速率较小，表现出最慢的衰减速率，在 2000 个循环后 SOH 仍保持在约 47%，游戏模式由于负载功率最大导致内阻发热加剧和电极材料的快速劣化，导致 SOH 呈现最快的衰减，混合模型预测其在约 1100 个循环时 SOH 就降至接近 0%，而简化模型预测的寿命约为 1220 个循环。视频播放和导航模式的衰减曲线介于两者之间。视频场景的混合模型预测寿命约为 1750 个循环，而导航场景约为 1250 个循环。三种场景下混合模型与简化模型的预测差异约为 100-200 个循环，并在电池寿命后期（SOH < 50%）尤为明显。这表明内阻随电池的老化显著增加使得对电池容量衰减的加速作用变得更加突出。

7 Recommendations

7.1 针对用户的使用建议

- 当进行游戏或导航等高负载场景时，电池耗减速率可达待机状态的 8-10 倍。因此，在高负载条件下，连续使用不超过 1.5 小时，或周期性静置冷却，每进行 1 小时高负载游戏后，建议静置 15 分钟以上，使电池温度回落至环境温度，从而延长使用时间与电池寿命。
- 在室内环境下，可以适当降低屏幕亮度以延长续航时间和减缓电池老化。
- 待机常亮限制：若需长期保持屏幕开启（如床头时钟、展示模式），强制设定亮度为 50% 可使电池循环寿命延长。当不需要屏幕常亮，尽量关闭屏幕。
- 避免边充边玩，充电过程中产生的焦耳热叠加高负载产热，导致电池温度升高，导致电池老化加快。

7.2 针对 OS 的建议

- 加入我们的基于 UKF 的电池状态估计与时间预测模型，来告知用户电池状态与续航时间。

- 当检测到电池温度过高时，对 CPU 进行降频限制功率，以降低温度，延缓电池老化。
- 根据环境光，自动调节屏幕亮度，以延长续航时间。

8 Model Evaluation and Further Discussion

8.1 Strengths

- 我们采用二阶 RC 等效电路模型，相比纯经验拟合更具物理可解释性，能够实现对 SOC 的高精度与高效率估计。
- 我们引入热动力学模型并与内阻、可用容量等参数进行耦合，这能够解释温度对电池性能的动态影响，增强了模型对复杂工况的解释力与一致性。
- 我们采用 GA 算法进行全局寻优，可一定程度避免局部最优，使 R_0, R_1, R_2, C_1, C_2 及初始 SOC 等关键参数的辨识更稳定，为后续预测提供可靠的模型基底。
- 我们采用的 UKF 算法能够处理 $E(SOC)$ 的非线性观测关系，实现 SOC 的在线估计、误差快速收敛，并可给出置信区间，从而同时评估预测精度与预测可信度。

8.2 Weaknesses

- 我们所建立的功率负载模型属于简化的模型，而真实手机功耗不只受 CPU、屏幕、GPS、network、后台应用的影响，可能呈现更强的非线性与突发性。
- OCV 拟合、等效电路参数辨识以及 UKF 中的 Q_k, R_k 等设定均依赖实测数据；更换机型、电池老化程度或系统功耗策略变化时，参数可能需要重新标定。
- 仅以端电压作为观测量时，在电压变化缓慢的工况（如待机）观测信息量不足，不确定性更易累积；同时 UKF 性能对 Q_k, R_k 选择较敏感，若设定不当可能出现跟踪抖动或收敛变慢。

9 Conclusion

本文针对智能手机锂电池的复杂动态行为，建立了一套多物理场耦合的连续时间数学模型，解决了非线性工况下的电量预测与剩余时间估计问题。首先，基于锂电池的二阶 RC 等效电路模型，通过基尔霍夫定律建立了状态空间微分方程组，精确刻画了欧姆极化、电化学极化与浓差极化的动态过程。针对模型参数未知问题，设计了遗传算法（GA）全局优化框架，以端电压均方根误差（RMSE）最小化为目标，辨识得到了包含欧姆内阻、极化参数及初始 SOC 在内的最优参数集。接着将模型扩展至热-电耦合域，引入 Arrhenius 方程描述温度对内阻与可用容量的指数影响，并建立了基于阿伦尼乌斯动力学的电池老化（SOH）微分方程。然后，为估计 SOC 与续航时间，我们部署了无迹卡尔曼滤波（UKF）算法，通过 Sigma 点变换处理 OCV-SOC 强非线性关系，最终得到 SOC 与续航时间的预测值。

References

- [1] Ahmed Abdelmotalib and Zhibo Wu. Power consumption in smartphones (hardware behaviourism). *International Journal of Computer Science Issues (IJCSI)*, 9(3):161–164, 05 2012.
- [2] Farhan Azmat Ali, Pieter Simoens, Tim Verbelen, Piet Demeester, and Bart Dhoedt. Mobile device power models for energy efficient dynamic offloading at runtime. *Journal of Systems and Software*, 113:173–187, 2016.
- [3] Mohammad Alipour, Carlos Ziebert, Fiorentino Valerio Conte, and Riza Kizilel. A review on temperature-dependent electrochemical properties, aging, and performance of lithium-ion cells. *Batteries*, 6(3), 2020.
- [4] Aaron Carroll and Gernot Heiser. An analysis of power consumption in a smartphone. In *Proceedings of the 2010 USENIX Annual Technical Conference (USENIX ATC '10)*, pages 21–21, Boston, MA, USA, 2010. USENIX Association.
- [5] Aaron Carroll and Gernot Heiser. An analysis of power consumption in a smartphone. In *USENIX Annual Technical Conference*, 2010.
- [6] Yixing Chen, Deqing Huang, Qiao Zhu, Weiqun Liu, Congzhi Liu, and Neng Xiong. A new state of charge estimation algorithm for lithium-ion batteries based on the fractional unscented kalman filter. *Energies*, 10(9), 2017.
- [7] Madeleine Ecker, Nerea Nieto, Stefan Käbitz, Johannes Schmalstieg, Heiko Blanke, Andreas Warnecke, and Dirk Uwe Sauer. Calendar and cycle life study of li(nimnco)o₂-based 18650 lithium-ion batteries. *Journal of Power Sources*, 248:839–851, 2014.
- [8] Google Inc. power_profile.xml — Android open source project. https://android.googlesource.com/platform/frameworks/base/+main/core/res/res/xml/power_profile.xml. Accessed: 2026-01-30.
- [9] Hongwen He, Rui Xiong, and Jinxin Fan. Evaluation of lithium-ion battery equivalent circuit models for state of charge estimation by an experimental approach. *Energies*, 4(4):582–598, 2011.
- [10] Seung-Ryeol Ohk, Seok Min Hong, and Young-Jin Kim. Phase-based predicting the battery remaining time for android mobile devices. In *2021 International Conference on Information and Communication Technology Convergence (ICTC)*, pages 942–944, 2021.
- [11] Hui Pang and Fengqi Zhang. Experimental data-driven parameter identification and state of charge estimation for a li-ion battery equivalent circuit model. *Energies*, 11(5), 2018.
- [12] Statista Research Department. Number of smartphone mobile network subscriptions worldwide from 2016 to 2025, with forecasts from 2025 to 2028. <https://www.statista.com/statistics/330695/number-of-smartphone-users-worldwide/>, 2025. Accessed: 2026-01-30.
- [13] Zichen Xu, Jie Zhou, Wenli Zheng, Yuhao Wang, and Minyi Guo. Exploiting big.little batteries for software defined management on mobile devices. *IEEE Transactions on Mobile Computing*, 21(6):1998–2012, 2022.